Proyecto ABP

Análisis estadístico sobre hábitos saludables en jóvenes universitarios

Curso: Estadística
Módulo: Inferencia estadística
Estudiante: Cintia García Ortega
Base de datos: Ultimate Student Productivity Dataset (5000 registros)

Introducción

El presente estudio analiza los hábitos de vida y productividad de estudiantes universitarios utilizando un conjunto de datos con múltiples variables relacionadas con el tiempo de estudio, uso de redes sociales, horas de sueño y actividades académicas.

El objetivo es aplicar herramientas estadísticas para comprender cómo se distribuyen estos hábitos y evaluar posibles patrones en el comportamiento estudiantil.

Lección 1: Método Científico y Rstadística

Método científico

Este estudio sigue el método científico aplicado a la estadística:

1. Observación del fenómeno: hábitos académicos y de vida de estudiantes universitarios.
2. Formulación del problema de investigación.
3. Construcción de hipótesis.
4. Recolección y análisis de datos.
5. Interpretación de resultados.

El análisis se realizará utilizando herramientas estadísticas y programación en Python para examinar patrones dentro del conjunto de datos.

Problema de investigación

Los hábitos de estudio, el tiempo en redes sociales y las horas de descanso pueden influir en la productividad académica de los estudiantes universitarios.

En este estudio se analizarán distintas variables relacionadas con el comportamiento diario de los estudiantes para comprender cómo se distribuyen estos hábitos dentro de una muestra de estudiantes universitarios.

Hipótesis

Hipótesis nula (H0):
No existe una relación significativa entre los hábitos de estudio y el uso del tiempo en actividades digitales entre los estudiantes.

Hipótesis alternativa (H1):
Existe una relación significativa entre los hábitos de estudio y el uso del tiempo en actividades digitales entre los estudiantes.

Variables del estudio

Variables cuantitativas:

- study_hours (horas de estudio)
- self_study_hours (horas de estudio autónomo)
- online_classes_hours (horas en clases online)
- social_media_hours (horas en redes sociales)

- sleep_hours (horas de sueño)
- exam_score (puntaje obtenido en el examen)

Variables cualitativas:

- gender (género)
- academic_level (nivel académico)

Diseño preliminar del estudio

El presente estudio utiliza un enfoque cuantitativo basado en el análisis estadístico de un conjunto de datos existente.

El diseño corresponde a un estudio observacional de tipo transversal, ya que analiza información recolectada en un momento determinado sin manipular las variables.

La investigación se basa en el análisis de una muestra de 5000 estudiantes universitarios incluidos en el conjunto de datos "Ultimate Student Productivity Dataset". A partir de esta base se examinan variables relacionadas con hábitos de estudio, uso del tiempo, bienestar y rendimiento académico.

El análisis estadístico se realizará utilizando herramientas de programación en Python dentro del entorno Google Colab, lo que permitirá explorar las distribuciones de los datos, calcular estadísticas descriptivas, analizar probabilidades y aplicar conceptos de inferencia estadística. Este diseño va a permitir identificar patrones y posibles relaciones entre hábitos de vida y productividad académica en estudiantes universitarios.

Lección 2: Probabilidad y Estadística

```
import pandas as pd
```

```
from google.colab import files
uploaded = files.upload()
```

Elegir archivos ultimate_stu…set_5000.csv

ultimate_student_productivity_dataset_5000.csv(text/csv) - 516810 bytes, last modified: 28/2/2026 - 100% done

```
Saving ultimate_student_productivity_dataset_5000.csv to ultimate_student_productivity_dataset_5000.csv
```

```
data = pd.read_csv("ultimate_student_productivity_dataset_5000.csv")

data.head()
```

	student_id	age	gender	academic_level	study_hours	self_study_hours	online_classes_hours	social_media_hours	gaming_hours
0	1	18	Other	High School	7.64	1.56	2.20	3.05	2.19
1	2	18	Other	High School	2.21	2.22	2.10	1.65	2.55
2	3	22	Male	High School	3.45	0.00	0.29	1.34	2.08
3	4	17	Other	High School	5.75	2.08	3.01	2.27	2.20
4	5	19	Other	High School	6.83	1.72	3.33	2.65	0.70

5 rows × 21 columns

Diccionario de variables

El dataset simulado contiene las siguientes variables utilizadas para analizar hábitos de estudio, bienestar y rendimiento académico en estudiantes.

- **student_id:** identificador único del estudiante.
- **age:** edad del estudiante.
- **gender:** género del estudiante.
- **academic_level:** nivel académico del estudiante.
- **study_hours:** horas de estudio totales.
- **self_study_hours:** horas dedicadas al estudio autónomo.
- **online_classes_hours:** horas de clases realizadas en modalidad online.

- **social_media_hours:** horas diarias dedicadas al uso de redes sociales.
- **gaming_hours:** horas dedicadas a videojuegos.
- **sleep_hours:** número de horas de sueño diarias.
- **screen_time_hours:** tiempo total frente a pantallas.
- **exercise_minutes:** minutos diarios de ejercicio físico.
- **caffeine_intake_mg:** consumo diario de cafeína en miligramos.
- **part_time_job:** indica si el estudiante tiene trabajo de medio tiempo.
- **upcoming_deadline:** indica si el estudiante tiene una entrega o evaluación próxima.
- **internet_quality:** calidad de la conexión a internet.
- **mental_health_score:** puntaje asociado al bienestar o salud mental del estudiante.
- **focus_index:** índice de concentración del estudiante.
- **burnout_level:** nivel de agotamiento académico o estrés.
- **productivity_score:** puntaje de productividad del estudiante.
- **exam_score:** puntaje obtenido en el examen.

```
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5000 entries, 0 to 4999
Data columns (total 21 columns):
 #   Column                Non-Null Count  Dtype
---  ------                --------------  -----
 0   student_id            5000 non-null   int64
 1   age                   5000 non-null   int64
 2   gender                5000 non-null   object
 3   academic_level        5000 non-null   object
 4   study_hours           5000 non-null   float64
 5   self_study_hours      5000 non-null   float64
 6   online_classes_hours  5000 non-null   float64
 7   social_media_hours    5000 non-null   float64
 8   gaming_hours          5000 non-null   float64
 9   sleep_hours           5000 non-null   float64
 10  screen_time_hours     5000 non-null   float64
 11  exercise_minutes      5000 non-null   int64
 12  caffeine_intake_mg    5000 non-null   int64
 13  part_time_job         5000 non-null   int64
 14  upcoming_deadline     5000 non-null   int64
 15  internet_quality      5000 non-null   object
 16  mental_health_score   5000 non-null   int64
 17  focus_index           5000 non-null   float64
 18  burnout_level         5000 non-null   float64
 19  productivity_score    5000 non-null   float64
 20  exam_score            5000 non-null   float64
dtypes: float64(11), int64(7), object(3)
memory usage: 820.4+ KB
```

Eventos aleatorios del estudio

En este estudio se analizan eventos aleatorios relacionados con los hábitos y el rendimiento académico de estudiantes universitarios.

Un evento aleatorio es un resultado posible dentro de un experimento cuyo resultado no puede predecirse con certeza.

Ejemplos de eventos dentro de este conjunto de datos son:

Evento A: un estudiante estudia más de 3 horas al día.

Evento B: un estudiante obtiene un puntaje de examen mayor a 80.

Evento C: un estudiante utiliza redes sociales más de 4 horas al día.

Estos eventos pueden analizarse estadísticamente para calcular probabilidades y observar patrones en el comportamiento académico de los estudiantes.

Representación conceptual mediante árbol de probabilidad

Los eventos aleatorios pueden representarse mediante árboles de probabilidad para visualizar las posibles combinaciones de resultados.

Por ejemplo, se pueden analizar dos eventos:

Evento A: el estudiante estudia más de 3 horas al día.

Evento B: el estudiante usa redes sociales más de 3 horas al día.

Un árbol de probabilidad permite representar las distintas combinaciones posibles:

- Estudia más de 3 horas y usa redes sociales más de 3 horas.
- Estudia más de 3 horas y usa redes sociales menos de 3 horas.
- Estudia menos de 3 horas y usa redes sociales más de 3 horas.
- Estudia menos de 3 horas y usa redes sociales menos de 3 horas.

Este tipo de representación permite calcular probabilidades conjuntas y analizar cómo se relacionan distintos hábitos de los estudiantes.

Espacio muestral

El espacio muestral corresponde al conjunto de todos los posibles resultados observados en el estudio.

En este caso, el espacio muestral está compuesto por los 5000 estudiantes incluidos en el conjunto de datos "Ultimate Student Productivity Dataset".

Cada registro representa un estudiante con diferentes características relacionadas con su comportamiento académico y hábitos diarios, como horas de estudio, uso de redes sociales, horas de sueño y rendimiento en exámenes.

Este conjunto de datos permite analizar distintos eventos y calcular probabilidades dentro de la muestra disponible.

Tipo de muestreo

El análisis utiliza una muestra de estudiantes provenientes de un conjunto de datos previamente recopilado.

Para efectos del estudio se considera un muestreo aleatorio simple, ya que cada estudiante del conjunto de datos tiene la misma probabilidad de ser seleccionado para el análisis.

El muestreo aleatorio simple permite reducir sesgos y facilita la aplicación de métodos estadísticos para estimar probabilidades y analizar patrones dentro de la población estudiada.

Simulación del diseño muestral

Para ilustrar el proceso de muestreo se seleccionó una muestra aleatoria de 100 estudiantes a partir del conjunto de datos original de 5000 registros. Esta muestra permite realizar análisis estadísticos representativos de la población estudiantil sin necesidad de trabajar con la totalidad de los datos.

```
sample_100 = data.sample(n=100, random_state=42)

sample_100.head()
```

	student_id	age	gender	academic_level	study_hours	self_study_hours	online_classes_hours	social_media_hours	gaming_h
1501	1502	21	Female	Postgraduate	1.69	1.27	2.03	3.01	
2586	2587	22	Other	High School	5.83	1.85	1.52	3.00	
2653	2654	23	Female	High School	2.97	0.67	2.80	1.72	
1055	1056	20	Male	High School	5.06	1.40	2.57	3.23	
705	706	19	Female	Undergraduate	4.36	2.25	1.19	0.24	

5 rows × 21 columns

```
prob_estudiar_mas_3 = (data["study_hours"] > 3).mean()

prob_estudiar_mas_3
```

```
np.float64(0.795)
```

Interpretación: La probabilidad calculada indica que aproximadamente el 79.5% de los estudiantes del conjunto de datos estudian más de 3 horas al día. Este valor representa la probabilidad del evento A dentro de la muestra analizada.

```
prob_redes_mas_3 = (data["social_media_hours"] > 3).mean()

prob_redes_mas_3
```

```
np.float64(0.4926)
```

Interpretación: El resultado indica que aproximadamente el 49.26% de los estudiantes utilizan redes sociales más de 3 horas al día. Este valor corresponde a la probabilidad del evento B dentro del conjunto de datos analizado.

Probabilidad de intersección

```
prob_interseccion = ((data["study_hours"] > 3) & (data["social_media_hours"] > 3)).mean()

prob_interseccion
```

```
np.float64(0.3918)
```

Interpretación $P(A \cap B)$: La probabilidad de intersección representa la ocurrencia simultánea de dos eventos. En este caso, aproximadamente el 39.18% de los estudiantes estudian más de 3 horas al día y además utilizan redes sociales más de 3 horas diarias.

Probabilidad de unión

```
prob_union = ((data["study_hours"] > 3) | (data["social_media_hours"] > 3)).mean()

prob_union
```

```
np.float64(0.8958)
```

Interpretación $P(A \cup B)$: La probabilidad de unión indica la ocurrencia de al menos uno de los dos eventos analizados. En este caso, aproximadamente el 89.58% de los estudiantes estudian más de 3 horas al día, utilizan redes sociales más de 3 horas o cumplen ambas condiciones.

Probabilidad complementaria

```
prob_complemento = (data["study_hours"] <= 3).mean()

prob_complemento
```

```
np.float64(0.205)
```

Interpretación $P(A^c)$: La probabilidad complementaria indica la ocurrencia del evento contrario. En este caso, aproximadamente el 20.5% de los estudiantes no estudian más de 3 horas al día.

Interpretación de probabilidades

Las probabilidades calculadas permiten analizar distintos patrones de comportamiento en los estudiantes.

Se analizaron eventos relacionados con el tiempo de estudio y el uso de redes sociales. A partir del conjunto de datos se calcularon probabilidades individuales, conjuntas y complementarias.

Estas medidas permiten comprender cómo se distribuyen ciertos hábitos dentro de la población estudiantil y constituyen la base para análisis estadísticos más avanzados que se desarrollarán en las siguientes lecciones.

Lección 3: Distribución de Probabilidad

Identificación del tipo de variables

Para aplicar distribuciones de probabilidad es necesario identificar si las variables son discretas o continuas.

Variables discretas del estudio:

- part_time_job (trabajo de medio tiempo)
- upcoming_deadline (fecha límite próxima)
- mental_health_score (puntaje de salud mental)

Estas variables representan conteos o categorías numéricas enteras.

Variables continuas del estudio:

- study_hours (horas de estudio)
- sleep_hours (horas de sueño)
- social_media_hours (horas en redes sociales)
- productivity_score (puntaje de productividad)
- exam_score (puntaje del examen)

Estas variables pueden tomar valores decimales y representan mediciones de tiempo o rendimiento académico.

La correcta identificación del tipo de variable permite seleccionar la distribución de probabilidad más adecuada para el análisis estadístico.

Selección de distribuciones de probabilidad

Según las características de las variables del estudio se pueden utilizar diferentes distribuciones de probabilidad.

Distribuciones discretas:

- Distribución binomial: puede utilizarse para modelar eventos con dos resultados posibles, por ejemplo tener o no trabajo de medio tiempo.
- Distribución de Poisson: se utiliza para modelar la cantidad de ocurrencias de eventos dentro de un intervalo.

Distribuciones continuas:

- Distribución normal: es adecuada para variables continuas como las horas de estudio o los puntajes de examen, donde los valores tienden a agruparse alrededor de un promedio.

En este estudio se analizarán principalmente variables continuas relacionadas con hábitos académicos, por lo que la distribución normal resulta una aproximación adecuada para describir su comportamiento.

Justificación de la elección de las distribuciones

Las variables discretas del estudio representan conteos o situaciones binarias. Por ejemplo, la variable part_time_job indica si un estudiante tiene o no un trabajo de medio tiempo, por lo que puede modelarse mediante una distribución binomial al tratarse de un evento con dos posibles resultados.

Las variables continuas como study_hours, sleep_hours, social_media_hours y exam_score representan mediciones numéricas que pueden tomar valores decimales dentro de un rango.

En muchos fenómenos sociales y educativos estas variables tienden a distribuirse alrededor de un valor promedio, por lo que la distribución normal resulta una aproximación adecuada para modelar su comportamiento.

El uso de la distribución normal permite calcular probabilidades asociadas a distintos rangos de valores y analizar cómo se comportan los hábitos académicos dentro de la población estudiantil.

```
data[["study_hours","sleep_hours","social_media_hours","exam_score"]].describe()
```

	study_hours	sleep_hours	social_media_hours	exam_score
count	5000.000000	5000.000000	5000.000000	5000.000000
mean	4.539594	7.016492	2.998086	18.803752
std	1.821665	1.163692	1.467949	12.130840
min	0.000000	4.000000	0.000000	1.000000
25%	3.250000	6.237500	1.990000	9.337500
50%	4.530000	7.010000	2.980000	18.010000
75%	5.760000	7.810000	4.030000	27.400000
max	11.840000	10.000000	8.280000	64.090000

```
# Probabilidad de que un estudiante estudie más de 4 horas al día

prob_estudio_alto = (data["study_hours"] > 4).mean()

prob_estudio_alto
```

```
np.float64(0.6142)
```

Interpretación de la probabilidad calculada

A partir del conjunto de datos se calculó la probabilidad de que un estudiante estudie más de 4 horas al día. El resultado obtenido fue 0.6142, lo que equivale aproximadamente a un 61.42%. Esto indica que una proporción importante de los estudiantes del conjunto de datos dedica más de cuatro horas diarias al estudio, lo que sugiere una alta dedicación académica dentro de la muestra analizada.

```
prob_dormir_mas7 = (data["sleep_hours"] > 7).mean()

prob_dormir_mas7
```

```
np.float64(0.5026)
```

Interpretación de la probabilidad de dormir más de 7 horas

Se calculó la probabilidad de que un estudiante duerma más de 7 horas al día utilizando la variable sleep_hours. Este cálculo permite observar la proporción de estudiantes que mantienen hábitos de descanso adecuados dentro de la muestra analizada.

```
import matplotlib.pyplot as plt

plt.hist(data["study_hours"], bins=30)
plt.title("Distribución de horas de estudio")
plt.xlabel("Horas de estudio")
plt.ylabel("Frecuencia")
plt.show()
```

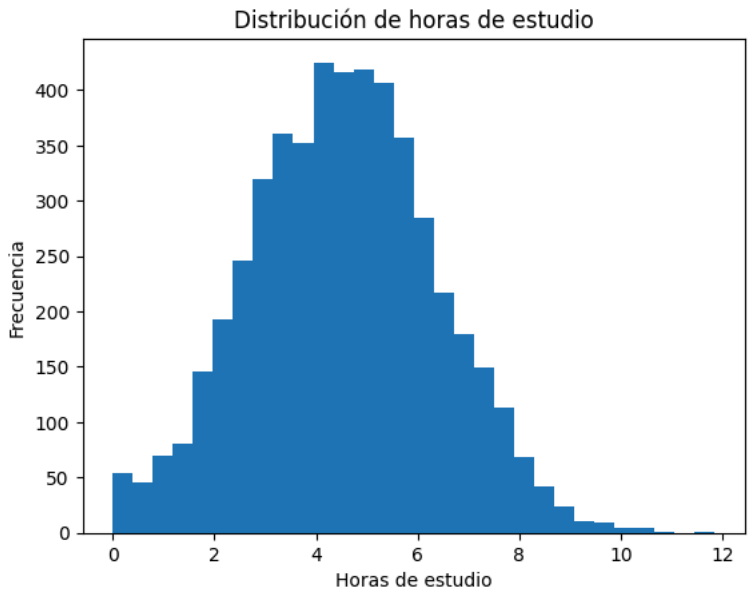


```
plt.hist(data["exam_score"], bins=30)

plt.title("Distribución de puntajes de examen")
plt.xlabel("Puntaje del examen")
plt.ylabel("Frecuencia")

plt.show()
```

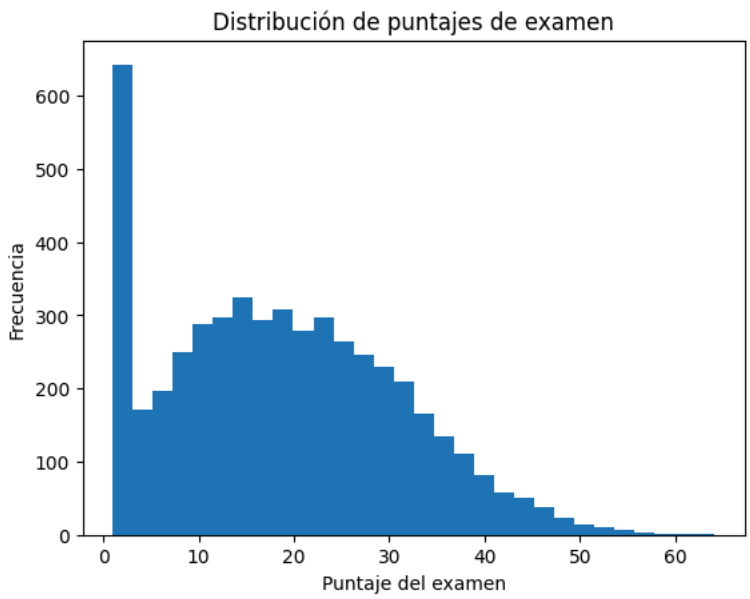

Interpretación de las distribuciones

Los histogramas permiten observar cómo se distribuyen variables clave del estudio como las horas de estudio y los puntajes de examen.

Se observa que los valores se concentran en ciertos rangos centrales, lo que sugiere un comportamiento agrupado de los datos.

Este patrón es consistente con una aproximación a una distribución normal, donde la mayor parte de los valores se ubican cerca de la media y disminuyen hacia los extremos.

Este tipo de análisis es fundamental para comprender la estructura de los datos antes de aplicar técnicas de inferencia estadística.

Lección 4: Distribución muestral y Teorema del Límite Central

Distribución muestral

La distribución muestral corresponde a la distribución de una estadística calculada a partir de múltiples muestras extraídas de una misma población.

En este estudio se utilizará el conjunto de datos de estudiantes universitarios como población inicial y se generarán múltiples muestras aleatorias para analizar cómo varía la media de ciertas variables.

Esto permite observar cómo se comportan las medias muestrales y analizar su dispersión en relación con la media poblacional.

Generación de múltiples muestras

```
import numpy as np

# Generar 1000 muestras de tamaño 50
sample_means = []

for i in range(1000):
    sample = data["study_hours"].sample(n=50)
    sample_means.append(sample.mean())
```

Distribución muestral de la media

```
import matplotlib.pyplot as plt

plt.hist(sample_means, bins=30)

plt.title("Distribución muestral de la media de horas de estudio")
plt.xlabel("Media de horas de estudio")
plt.ylabel("Frecuencia")

plt.show()
```

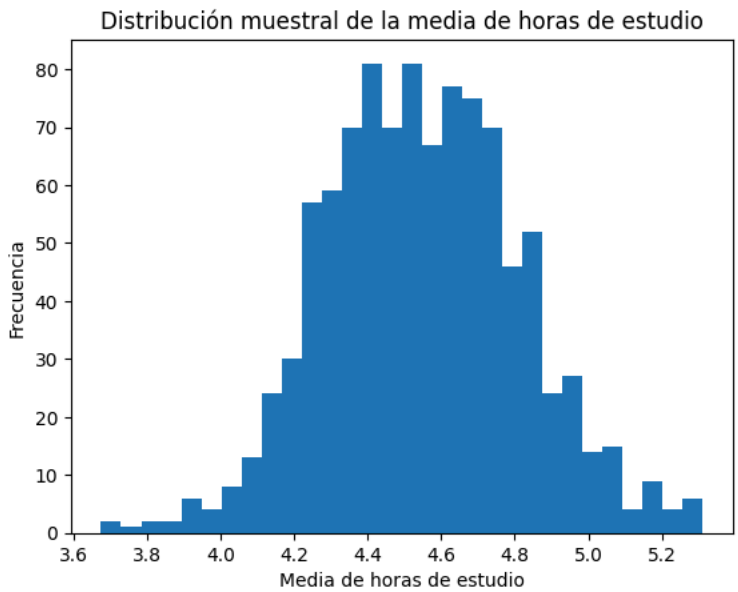

Comparación entre media poblacional y media muestral

```
# media poblacional
media_poblacion = data["study_hours"].mean()

# media de las medias muestrales
media_muestral = np.mean(sample_means)

media_poblacion, media_muestral
```

```
(np.float64(4.539594), np.float64(4.549999799999999))
```

Verificación empírica del Teorema del Límite Central

Los resultados muestran que la media de las medias muestrales es muy cercana a la media poblacional.

Esto confirma empíricamente el Teorema del Límite Central, el cual establece que al tomar múltiples muestras aleatorias de tamaño suficiente, la distribución de sus medias tiende a aproximarse a una distribución normal y su promedio se aproxima al valor real de la población.

Efecto del tamaño muestral en la dispersión

```
sample_means_10 = []

for i in range(1000):
    sample = data["study_hours"].sample(n=10)
    sample_means_10.append(sample.mean())

plt.hist(sample_means_10, bins=30)

plt.title("Distribución muestral con tamaño de muestra 10")
plt.xlabel("Media de horas de estudio")
plt.ylabel("Frecuencia")

plt.show()
```

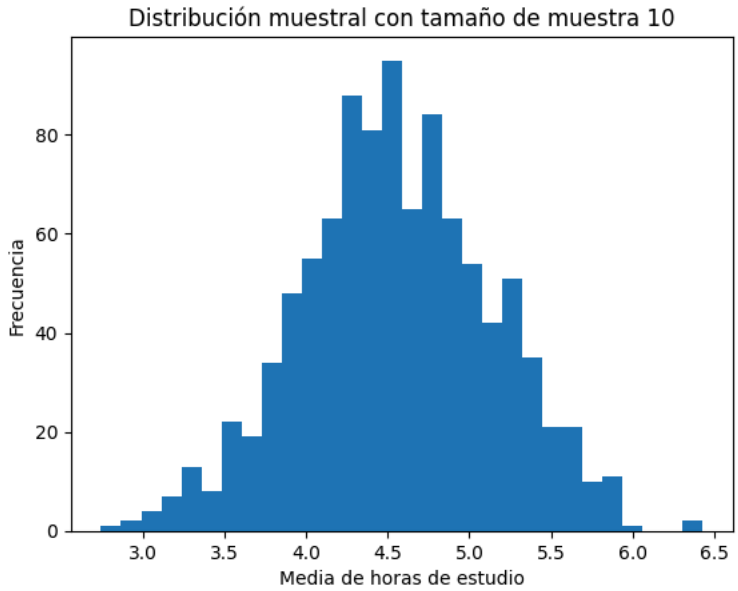

Análisis de la dispersión según tamaño muestral

Al reducir el tamaño de las muestras se observa que la distribución de las medias presenta una mayor dispersión.

Esto ocurre porque las muestras pequeñas tienen mayor variabilidad. A medida que el tamaño de muestra aumenta, las medias muestrales tienden a concentrarse alrededor de la media poblacional.

Este comportamiento está relacionado con el error estándar de la media, el cual disminuye cuando aumenta el tamaño muestral.

Comparación entre distribución poblacional y distribución muestral

La distribución original de las horas de estudio corresponde a la distribución poblacional del dataset.

Al generar múltiples muestras y calcular sus medias se obtiene la distribución muestral de la media.

Se observa que la distribución muestral presenta una forma más concentrada alrededor de la media, lo cual es consistente con la teoría estadística y con el Teorema del Límite Central.

Interpretación final

Al generar múltiples muestras aleatorias del conjunto de datos y calcular sus medias se observa que la distribución de estas medias tiende a aproximarse a una distribución normal.

Este resultado es consistente con el Teorema del Límite Central, el cual establece que, cuando el tamaño de muestra es suficientemente grande, la distribución de las medias muestrales tiende a ser normal, independientemente de la distribución original de los datos.

Además, se observa que al aumentar el tamaño de la muestra la dispersión de las medias disminuye, lo que significa que las estimaciones muestrales se aproximan cada vez más a la media poblacional.

Lección 5: Inferencia e Intervalos de confianza para la media

Cálculo de Intervalo de Confianza (Primera Variable)

```
import numpy as np
import scipy.stats as stats

# Intervalo de confianza para study_hours

media = data["study_hours"].mean()
std = data["study_hours"].std()
n = len(data)

intervalo_95 = stats.t.interval(0.95, df=n-1, loc=media, scale=std/np.sqrt(n))

intervalo_95
```

```
(np.float64(4.489088725070035), np.float64(4.590099274929965))
```

Con 95% de confianza la media real está en ese rango

Cálculo de Intervalo de Confianza (Segunda Variable)

```
# Intervalo de confianza para sleep_hours

media_sleep = data["sleep_hours"].mean()
std_sleep = data["sleep_hours"].std()

intervalo_sleep_95 = stats.t.interval(0.95, df=n-1, loc=media_sleep, scale=std_sleep/np.sqrt(n))

intervalo_sleep_95
```

```
(np.float64(6.984228880541639), np.float64(7.04875511945836))
```

```
ic_90 = stats.t.interval(0.90, df=n-1, loc=media, scale=std/np.sqrt(n))
ic_95 = stats.t.interval(0.95, df=n-1, loc=media, scale=std/np.sqrt(n))
ic_99 = stats.t.interval(0.99, df=n-1, loc=media, scale=std/np.sqrt(n))

ic_90, ic_95, ic_99
```

```
((np.float64(4.49721104534045), np.float64(4.581976954659551)),
 (np.float64(4.489088725070035), np.float64(4.590099274929965)),
 (np.float64(4.47320954186751), np.float64(4.6059784581324905)))
```

```
# Tomar muestra pequeña

sample_small = data.sample(50)

media_small = sample_small["study_hours"].mean()
std_small = sample_small["study_hours"].std()
n_small = len(sample_small)

intervalo_small = stats.t.interval(0.95, df=n_small-1, loc=media_small, scale=std_small/np.sqrt(n_small))
```

```
intervalo_small
```

```
(np.float64(4.3662052921905214), np.float64(5.4017947078094775))
```

Interpretación de los intervalos de confianza

Los intervalos de confianza permiten estimar el rango en el cual se encuentra el verdadero valor de la media poblacional.

Los resultados muestran que las medias de variables como las horas de estudio y las horas de sueño se encuentran dentro de rangos relativamente acotados cuando se utilizan muestras grandes.

Además, se observa que al aumentar el nivel de confianza (por ejemplo de 90% a 99%) el intervalo se vuelve más amplio, ya que se busca aumentar la probabilidad de contener el valor real del parámetro.

También se evidencia que las muestras más pequeñas generan intervalos más amplios, lo que indica menor precisión en la estimación.

Lección 6: Test de Significancia

Test de hipótesis para la media

Primero hacemos una prueba para ver si la media de la muestra es distinta a la media poblacional.

```
data.columns
```

```
Index(['student_id', 'age', 'gender', 'academic_level', 'study_hours',
       'self_study_hours', 'online_classes_hours', 'social_media_hours',
       'gaming_hours', 'sleep_hours', 'screen_time_hours', 'exercise_minutes',
       'caffeine_intake_mg', 'part_time_job', 'upcoming_deadline',
       'internet_quality', 'mental_health_score', 'focus_index',
       'burnout_level', 'productivity_score', 'exam_score'],
      dtype='object')
```

```
import scipy.stats as stats

# seleccionamos la variable de interés
exam_scores = data['exam_score']

# media poblacional hipotética
mu = 70

# test t de una muestra
t_stat, p_value = stats.ttest_1samp(exam_scores, mu)

print("Estadístico t:", t_stat)
print("Valor p:", p_value)
```

```
Estadístico t: -298.42298632402145
Valor p: 0.0
```

Interpretación Test de hipótesis para la media

Se realizó una prueba **t de una muestra** para evaluar si el promedio de los puntajes del examen (`exam_score`) es diferente de 70.

Hipótesis:

H_0: $\mu = 70$ H_1: $\mu \neq 70$

El resultado del test entregó:

- Estadístico t = -298.42
- Valor p = 0.0

Dado que el **valor p es menor que α = 0.05**, se **rechaza la hipótesis nula**.

Esto indica que existe evidencia estadística suficiente para afirmar que el promedio del puntaje de examen en la muestra **es significativamente diferente de 70**.

Comparación del valor-p con α

Decisión estadística: para tomar la decisión se compara el **valor p** con el nivel de significancia **α = 0.05**.

- Si $p < \alpha \rightarrow$ se rechaza la hipótesis nula.
- Si $p \geq \alpha \rightarrow$ no se rechaza la hipótesis nula.

En este caso:

$p = 0.0 < 0.05$

Por lo tanto, **se rechaza la hipótesis nula**, lo que indica que la media observada es significativamente diferente del valor hipotético de 70.

Error tipo I y error tipo II

En el contexto de este análisis:

- **Error tipo I:** rechazar la hipótesis nula cuando en realidad es verdadera. En este caso sería concluir que el promedio del puntaje de examen es diferente de 70 cuando en realidad sí es 70.
- **Error tipo II:** no rechazar la hipótesis nula cuando es falsa. En este caso sería concluir que el promedio del puntaje de examen es 70 cuando en realidad es diferente.

El nivel de significancia α = 0.05 representa la probabilidad de cometer un **error tipo I**.

Interpretación

El test de hipótesis realizado muestra que el valor p obtenido es menor que el nivel de significancia α = 0.05. Por lo tanto, se rechaza la hipótesis nula.

Esto indica que existe evidencia estadística suficiente para afirmar que el promedio de los puntajes de examen en el conjunto de datos analizado es significativamente diferente de 70.

```
#Histograma del puntaje de examen
import matplotlib.pyplot as plt

plt.hist(data['exam_score'], bins=20)
plt.title("Distribución de puntajes de examen")
plt.xlabel("Puntaje")
plt.ylabel("Frecuencia")
plt.show()
```

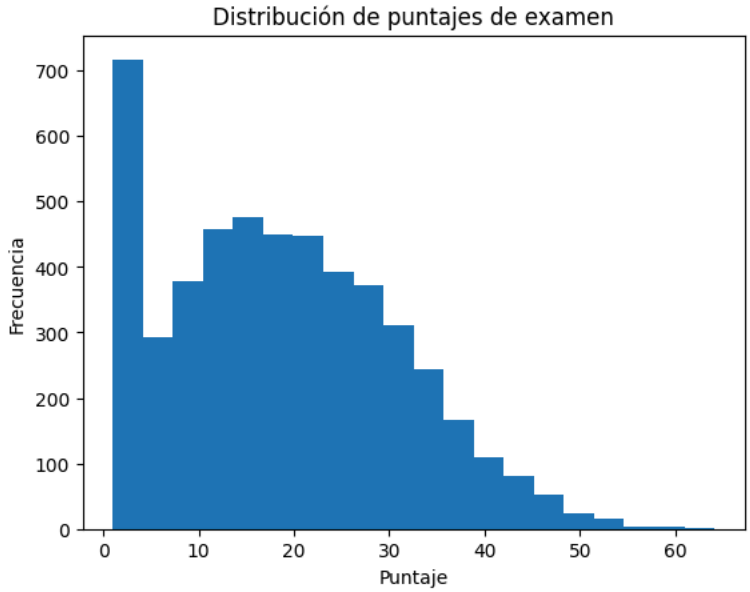

```
#Relación entre horas de estudio y puntaje
plt.scatter(data['study_hours'], data['exam_score'])
plt.title("Relación entre horas de estudio y puntaje de examen")
plt.xlabel("Horas de estudio")
plt.ylabel("Puntaje de examen")
plt.show()
```

```
#Relación entre sueño y rendimiento
plt.scatter(data['sleep_hours'], data['exam_score'])
plt.title("Relación entre horas de sueño y puntaje de examen")
plt.xlabel("Horas de sueño")
plt.ylabel("Puntaje de examen")
plt.show()
```

```
#Burnout versus rendimiento

plt.scatter(data['burnout_level'], data['exam_score'])
plt.title("Relación entre burnout y puntaje de examen")
plt.xlabel("Nivel de burnout")
plt.ylabel("Puntaje de examen")
plt.show()
```

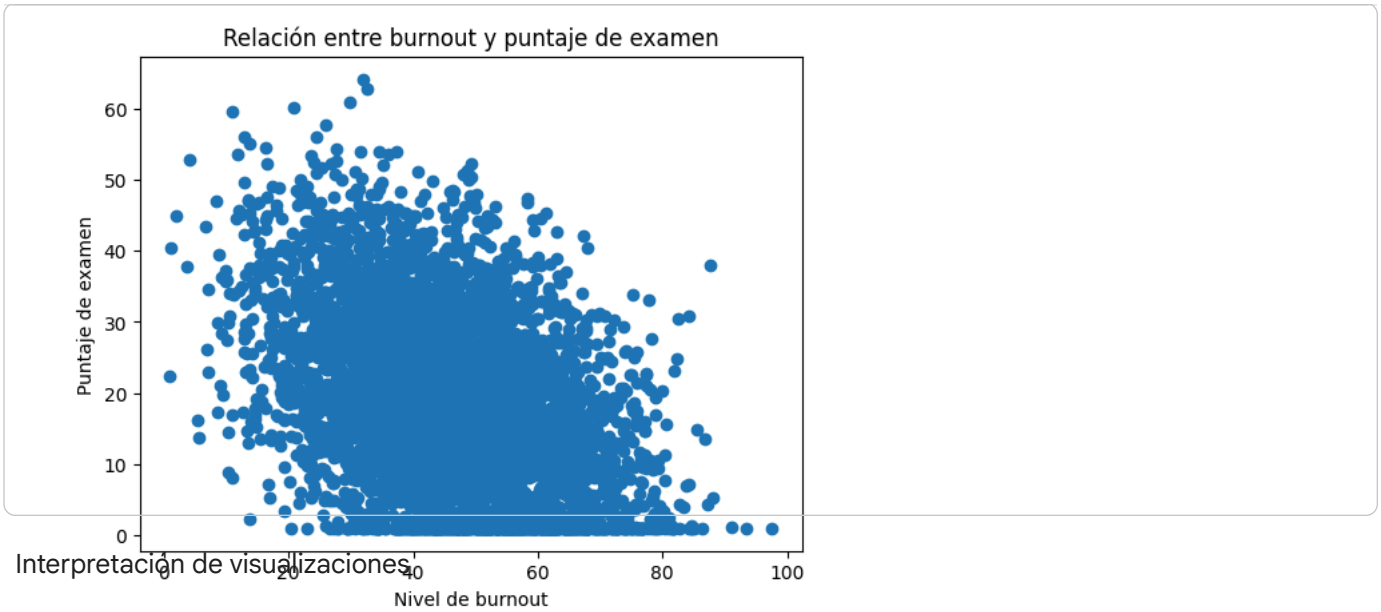

Interpretación de visualizaciones

Los gráficos permiten observar diferentes relaciones entre hábitos de los estudiantes y su rendimiento académico.

La distribución del puntaje de examen muestra cómo se concentran los resultados obtenidos por los estudiantes en el dataset simulado.

La relación entre horas de estudio y puntaje de examen sugiere que un mayor tiempo dedicado al estudio tiende a asociarse con mejores resultados académicos.