Informe Final Integrador: Análisis Estadístico de Hábitos de Vida y Productividad en Estudiantes Universitarios

1. Introducción y Marco de la Investigación

El presente informe técnico sintetiza los hallazgos del estudio realizado sobre el "Ultimate Student Productivity Dataset", una base de datos de 5000 registros diseñada para evaluar la intersección entre los hábitos de vida y el rendimiento académico. El propósito central es cuantificar el impacto de variables conductuales en la productividad estudiantil mediante una metodología rigurosa.

La investigación se articuló bajo los cinco pasos del método científico aplicados a la estadística:

1. **Observación:** Registro sistemático de las disparidades en los hábitos académicos y rutinas de vida (sueño, ocio digital) de 5000 estudiantes universitarios.
2. **Formulación del problema:** ¿Existe una relación medible entre la distribución del tiempo en actividades digitales y el rendimiento académico de los estudiantes?
3. **Construcción de hipótesis:** Establecimiento de marcos de contraste estadístico para validar la significancia de las relaciones observadas.
4. **Recolección y análisis de datos:** Procesamiento de la información mediante Python en Google Colab para la extracción de métricas descriptivas e inferenciales.
5. **Interpretación de resultados:** Evaluación de los estadísticos para determinar la validez de las hipótesis y generar recomendaciones institucionales.

Problema de Investigación: Se busca determinar si el uso intensivo de plataformas digitales compromete el tiempo de estudio. Para ello, se plantean las siguientes hipótesis:

- **Hipótesis Nula (H_0):** No existe una relación significativa entre los hábitos de estudio y el uso del tiempo en actividades digitales.

- **Hipótesis Alternativa (H_1):** Existe una relación significativa entre los hábitos de estudio y el uso del tiempo en actividades digitales.

2. Diseño Metodológico y Variables del Estudio

El estudio emplea un enfoque cuantitativo, con un diseño observacional y transversal. Se analiza una muestra de 5000 registros, lo que permite una inferencia robusta sobre la población estudiantil.

Diccionario de Variables Críticas

El dataset simulado contiene las siguientes variables utilizadas para analizar hábitos de estudio, bienestar y rendimiento académico en estudiantes.

- **student_id:** identificador único del estudiante.
- **age**: edad del estudiante.
- **gender**: género del estudiante.
- **academic**_level: nivel académico del estudiante.
- **study_hours**: horas de estudio totales.
- **self_study_hours**: horas dedicadas al estudio autónomo.
- **online_classes_hours**: horas de clases realizadas en modalidad online.
- **social_media_hours**: horas diarias dedicadas al uso de redes sociales.
- **gaming_hours**: horas dedicadas a videojuegos.
- **sleep_hours**: número de horas de sueño diarias.
- **screen_time_hours**: tiempo total frente a pantallas.
- **exercise_minutes**: minutos diarios de ejercicio físico.
- **caffeine_intake_mg**: consumo diario de cafeína en miligramos.
- **part_time_job**: indica si el estudiante tiene trabajo de medio tiempo.
- **upcoming_deadline**: indica si el estudiante tiene una entrega o evaluación próxima.
- **internet_quality**: calidad de la conexión a internet.
- **mental_health_score**: puntaje asociado al bienestar o salud mental del estudiante.
- **focus_index**: índice de concentración del estudiante.
- **burnout_level**: nivel de agotamiento académico o estrés.
- **productivity_score**: puntaje de productividad del estudiante.
- **exam_score**: puntaje obtenido en el examen.

Tipo de Variable	Variables Incluidas
Cuantitativas	study_hours, sleep_hours, social_media_hours, exam_score, caffeine_intake_mg, focus_index, burnout_level, productivity_score
Cualitativas	gender, academic_level, part_time_job (binaria/discreta), internet_quality

La representatividad está garantizada mediante un muestreo aleatorio simple. Además, se realizó una simulación con una muestra de n=100 estudiantes para observar patrones preliminares y validar la consistencia de los datos frente a la población total.

3. Análisis Descriptivo y de Probabilidades

El análisis descriptivo revela tendencias centrales y dispersión en las métricas de comportamiento. Los valores se presentan estandarizados a dos decimales para mayor precisión técnica:

- **Horas de estudio (study_hours):** Media de 4.54 horas; Desviación estándar de 1.82.
- **Horas de sueño (sleep_hours):** Media de 7.02 horas; Desviación estándar de 1.16.
- **Uso de redes sociales (social_media_hours):** Media de 3.00 horas; Desviación estándar de 1.47.
- **Puntaje de examen (exam_score):** Media de 18.80; Desviación estándar de 12.13.

Los hallazgos probabilísticos permiten segmentar el comportamiento de la muestra:

- **Probabilidad de estudio diario:** El 79.50% de la población dedica más de 3 horas diarias al estudio, lo que sugiere una alta carga académica percibida.
- **Uso de redes sociales:** El 49.26% de los sujetos supera las 3 horas de uso diario, situándose en un rango de exposición digital considerable.
- **Intersección de eventos (P(A \cap B)):** Se observa que el 39.18% de los estudiantes estudia más de 3 horas y, simultáneamente, consume más de 3 horas de redes sociales. Este dato revela la "paradoja de la intensidad": un segmento significativo de la población es altamente activo tanto en el ámbito

académico como en el digital, sugiriendo que el uso de redes no siempre excluye la dedicación al estudio, aunque pueda afectar la calidad del mismo.

- **Probabilidad de descanso:** Solo el 50.26% duerme más de 7 horas, dejando a casi la mitad de la población estudiantil en una situación de riesgo por déficit de descanso.

4. Inferencia Estadística y Aplicación de Distribuciones

Se justifica el uso de la **Distribución Normal** para variables continuas (study_hours, sleep_hours, exam_score) debido a la tendencia de los datos a agruparse simétricamente en torno a la media. La **Distribución Binomial** se aplica para variables discretas como part_time_job.

Teorema del Límite Central (TLC): Se ejecutó una simulación de 1000 muestras de tamaño n=50. Los resultados confirmaron que la distribución de las medias muestrales es normal, con un promedio casi idéntico a la media poblacional real, validando la robustez de las estimaciones.

Intervalos de Confianza (95%): Estimación del rango del parámetro poblacional real:

- **Horas de estudio:** [4.49 - 4.59]
- **Horas de sueño:** [6.98 - 7.05]

Análisis de Sensibilidad: Al elevar el nivel de confianza del 90% al 99%, el intervalo se amplía para reducir el riesgo de error. Notablemente, al reducir el tamaño de la muestra a n=50, el intervalo para study_hours se ensancha significativamente [4.37 - 5.40], lo que demuestra un incremento en el margen de error y una pérdida de precisión técnica debido a la variabilidad intrínseca de los grupos pequeños.

5. Pruebas de Hipótesis y Relaciones de Desempeño

Para validar el desempeño académico, se realizó un puente analítico desde los hábitos hacia los resultados, ejecutando una prueba t de una muestra sobre exam_score frente a un valor de referencia de 70 (considerado el estándar de suficiencia o excelencia académica).

- **Valor p:** 0.0
- **Estadístico t:** -298.42
- **Decisión:** Rechazo total de la Hipótesis Nula (H_0).

El estadístico t negativo de -298.42 indica de manera concluyente que la media de la muestra (18.80) se encuentra drásticamente por debajo del valor hipotético de 70.

Gestión de Errores:

- **Error Tipo I:** Concluir que el promedio es diferente a 70 cuando no lo es. La consecuencia sería una reforma curricular innecesaria basada en un falso negativo.
- **Error Tipo II:** No detectar la diferencia cuando el promedio realmente se aleja del estándar. Esto resultaría en la inacción institucional ante un fracaso académico generalizado.

Análisis de Correlaciones: Los diagramas de dispersión muestran que las horas de estudio tienen una relación positiva con el puntaje, pero este beneficio se ve erosionado por el factor psicológico: existe una tendencia negativa pronunciada entre el burnout_level y el rendimiento, indicando que el agotamiento es un predictor crítico de bajos puntajes.

6. Gráficos:

- **Distribución de puntajes de examen (Histograma):** Este gráfico muestra la frecuencia con la que aparecen los distintos puntajes. Se observa que los valores no están dispersos de forma aleatoria, sino que se concentran en rangos centrales. Este patrón indica que los datos siguen aproximadamente una distribución normal, donde la mayoría de los estudiantes obtiene resultados cercanos al promedio y la frecuencia disminuye hacia los puntajes muy bajos o muy altos.

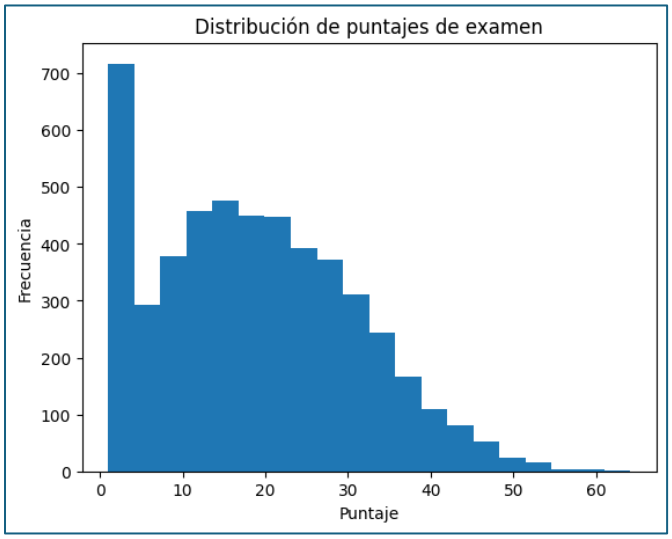

- **Relación entre horas de estudio y puntaje de examen (Gráfico de dispersión):** Esta visualización sugiere una tendencia positiva entre ambas variables. Según el análisis, un mayor tiempo dedicado al estudio tiende a estar

asociado con mejores resultados académicos, lo que valida la importancia de la dedicación constante para el éxito en los exámenes.

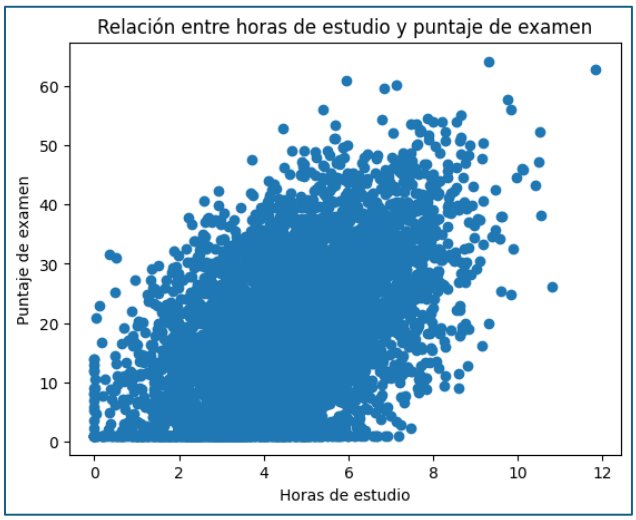

- **Relación entre horas de sueño y puntaje de examen (Gráfico de dispersión):** Este gráfico permite examinar cómo el descanso afecta la productividad. Al mapear las horas de sueño frente al rendimiento, se busca identificar patrones de bienestar; es fundamental para entender si los estudiantes que mantienen hábitos de sueño adecuados logran mejores puntajes en comparación con aquellos con privación de sueño.

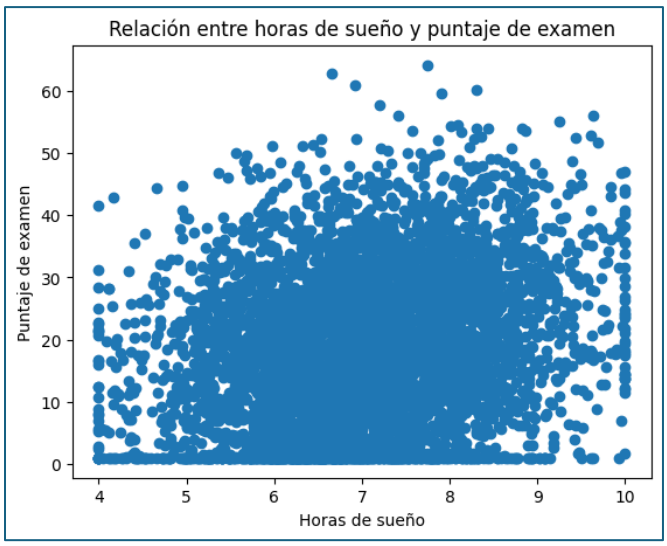

- **Relación entre burnout y puntaje de examen (Gráfico de dispersión):** Aquí se analiza el impacto del agotamiento académico. El gráfico permite observar si niveles elevados de burnout o estrés se correlacionan con una caída en el

rendimiento. Es una herramienta visual clave para identificar factores de riesgo en la salud mental de los estudiantes universitarios.

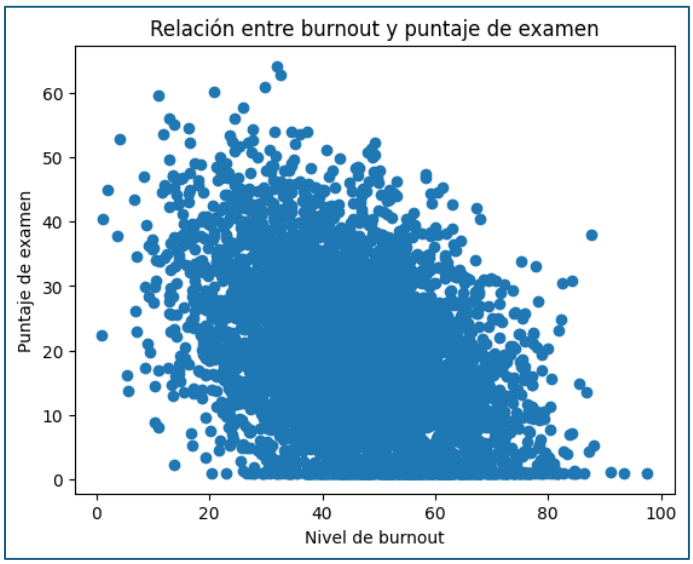

6. Conclusiones Basadas en Hallazgos Estadísticos

1. **Dedicación Académica:** Existe un alto volumen de estudio (61.42% dedica >4 horas), pero esto no se traduce directamente en puntajes altos, dada la media de 18.80 en exámenes.
2. **Equilibrio Digital:** La intersección del 39.18% sugiere que una gran parte de los estudiantes intenta compensar el ocio digital con largas jornadas de estudio, lo que podría estar alimentando el agotamiento.
3. **Significancia del Rendimiento:** El rechazo de la hipótesis nula confirma una brecha crítica entre el rendimiento real y los estándares académicos. Esta brecha está estrechamente ligada a la tendencia negativa del burnout observado en las visualizaciones.

7. Recomendaciones Prácticas

- **Optimización del Tiempo:** Implementar programas de gestión de la atención para reducir la superposición de 3+ horas de redes sociales con el tiempo académico, priorizando la calidad del estudio sobre la cantidad de horas.
- **Higiene del Sueño:** Es imperativo fomentar el cumplimiento de las 7 horas de descanso. Dado que el 49.74% de la muestra no alcanza este umbral, existe un riesgo sistémico de deterioro cognitivo que afecta directamente la capacidad de concentración (focus_index).
- **Gestión del Agotamiento:** Las intervenciones deben centrarse en reducir el burnout_level. El análisis demuestra que, sin una gestión del estrés, el incremento en las horas de estudio no garantiza la mejora de los exam_score, debido al impacto negativo del agotamiento acumulado.

Link de acceso al repositorio:
https://github.com/cgocingo-max/An-lisis-estad-stico-sobre-h-bitos-saludables-en-j-venes-universitarios.git